

Métodos Estadísticos

Tarea 1

Métodos Estadísticos. Ciencia de datos

González Paz Edgar

1. Considere una muestra aleatoria X_1, \dots, X_n con función de densidad

$$f(x|\theta) = 1_{\{\theta < x < \theta+1\}}, \theta \in \mathbb{R}$$

1.1 Calcule un estimador para θ por el método de momentos y por el método de máxima verosimilitud, diga si estos son insesgados y suficientes para theta.

Primero calculamos la esperanza de nuestra función de densidad

$$\mathbb{E}(x) = \int_{\mathbb{R}} x f(x|\theta) dx = \int_{\theta}^{\theta+1} x dx = \frac{x^2}{2} \Big|_{\theta}^{\theta+1} = \frac{(\theta+1)^2}{2} - \frac{\theta^2}{2} = \frac{\theta^2 + 2\theta + 1 - \theta^2}{2} = \frac{2\theta + 1}{2}$$

Entonces, igualamos el primer momento muestral a la esperanza para obtener el estimador de momentos:

$$\begin{aligned} \Rightarrow \frac{2\theta + 1}{2} &= \frac{1}{n} \sum_{i=1}^n x_i \\ \Rightarrow 2\theta + 1 &= \frac{2}{n} \sum_{i=1}^n x_i \\ \Rightarrow 2\theta &= \frac{2}{n} \sum_{i=1}^n x_i - 1 \\ \Rightarrow \hat{\theta}_{MM} &= \frac{2\bar{X} - 1}{2} \end{aligned}$$

Para el $\hat{\theta}_{MLE}$ obtenemos la función de verosimilitud del parámetro θ :

$$\begin{aligned} L(\theta|X) &= \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n 1_{\{\theta < x_i < \theta+1\}} = \prod_{i=1}^n 1_{\{\theta < x_i\}} \prod_{i=1}^n 1_{\{x_i < \theta+1\}} = 1_{\{X_1 > \theta\}} 1_{\{X_n < \theta+1\}} \\ &= 1_{\{X_1 > \theta\}} 1_{\{X_n - 1 < \theta\}} = 1_{\{X_{(n)} - 1 < \theta < X_{(1)}\}} \\ 1_{\{X_{(n)} - 1 < \theta < X_{(1)}\}} &= \begin{cases} 1, & \text{si } X_{(n)} - 1 \leq \theta \leq X_{(1)} \\ 0, & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

No hay un estimador único de Máxima Verosimilitud, puede existir más de un estimador de θ tal que cumpla:

$$X_{(n)} - 1 \leq \theta \leq X_{(1)}$$

Es decir, aquellos que sean de la forma

$$\hat{\theta}_{MLE} = w_1(X_{(n)} - 1) + w_2 X_{(1)}$$

donde $w_1, w_2 \in \mathbb{R}^+$, es decir, $w_1, w_2 \geq 0$ t.q. $w_1 + w_2 = 1$.

¿Son insesgados y suficientes para θ ?

Primero, probamos para el $\hat{\theta}_{MLE}$. Necesitamos obtener la esperanza de este estadístico.

$$\mathbb{E}(\hat{\theta}_{MLE}) = \mathbb{E}(w_1(X_{(n)} - 1) + w_2 X_{(n)}) = w_1 \mathbb{E}(X_{(n)}) - \mathbb{E}(w_1) + w_2 \mathbb{E}(X_{(n)})$$

Debemos obtener la esperanza del estadístico $X_{(n)}$. Sea $Y = X_{(n)}$

$$\mathbb{E}(X_{(n)}) = \mathbb{E}(Y) = \int_{\mathbb{R}} y \frac{n(y - \theta)^{n-1}}{(\theta + 1 - \theta)^n} 1_{\{\theta < y < \theta+1\}} dy = n \left(\int_{\theta}^{\theta+1} y(y - \theta)^{n-1} dy \right)$$

Hacemos un cambio de variable.

Sea $u = y - \theta$, entonces $y = u + \theta$. Para los límites,

Si $y = \theta \rightarrow u = 0$,

Si $y = \theta + 1 \rightarrow u = 1$

$$\begin{aligned} \Rightarrow n \left(\int_0^1 (u + \theta) u^{n-1} du \right) &= n \left(\int_0^1 u^n + \theta u^{n-1} du \right) = n \left(\int_0^1 u^n du + \theta \int_0^1 u^{n-1} du \right) \\ &= n \left(\frac{u^{n+1}}{n+1} \Big|_0^1 + \theta \frac{u^n}{n} \Big|_0^1 \right) = n \left(\frac{1}{n+1} + \frac{\theta}{n} \right) \\ &= \frac{n}{n+1} + \theta^n = \frac{n + \theta(n+1)}{n+1} \end{aligned}$$

También debemos obtener la esperanza del estadístico $X_{(1)}$. Sea $Y = X_{(1)}$

$$\Rightarrow \mathbb{E}(X_{(1)}) = \mathbb{E}(y) = \int_{\mathbb{R}} yn(\theta + 1 - y)^{n-1} 1_{\{\theta < y < \theta+1\}} dy = n \left(\int_{\theta}^{\theta+1} y(\theta + 1 - y) dy \right)$$

Hacemos un cambio de variable.

Sea $u = \theta + 1 - y$, entonces $y = \theta + 1 - u$. Para los límites,

Si $y = \theta \rightarrow u = 1$,

Si $y = \theta + 1 \rightarrow u = 0$

$$\begin{aligned} &dx = -du \\ &= n \left(\int_1^0 (\theta + 1 - u) u^{n-1} - du \right) = n \left(\int_0^1 \theta u^{n-1} du + \int_0^1 u^{n-1} du - \int_0^1 u^n du \right) \\ &= n \left(\theta \frac{u^n}{n} \Big|_1^0 + \frac{u^n}{n} \Big|_1^0 - \frac{u^{n+1}}{n+1} \Big|_1^0 \right) = n \left(\frac{\theta}{n} + \frac{1}{n} - \frac{1}{n+1} \right) \\ &= \theta + 1 - \frac{n}{n+1} = \theta + \frac{1}{n+1} \end{aligned}$$

Retomando

$$\begin{aligned}
 \Rightarrow \mathbb{E}(\hat{\theta}_{MLE}) &= w_1 \left(\frac{n + \theta(n+1)}{n+1} \right) - w_1 + w_2 \left(\theta + \frac{1}{n+1} \right) \\
 &= w_1 \left(\frac{n + \theta(n+1)}{n+1} - 1 \right) + w_2 \left(\theta + \frac{1}{n+1} \right) \\
 &= w_1 \left(\frac{n + \theta n + \theta - n - 1}{n+1} \right) + w_2 \left(\frac{\theta n + \theta + 1}{n+1} \right) \\
 &= \frac{w_1 n \theta + w_1 \theta - w_1 + w_2 n \theta + w_2 n \theta + w_2 \theta + w_2}{n+1}
 \end{aligned}$$

Entonces $\mathbb{E}(\hat{\theta}_{MLE}) = \theta \iff w_1 = \frac{1}{2} \ w_2 = \frac{1}{2}$. Por lo tanto, un MLE insesgado sería

$$\hat{\theta}_{MLE} = \frac{X_{(n)} - 1}{2} + \frac{X_{(1)}}{2}$$

Ahora bien, para $\hat{\theta}_{MM}$, tenemos que:

$$\mathbb{E}(\hat{\theta}_{MM}) = \mathbb{E} \left(\frac{2\bar{X} - 1}{2} \right) = \mathbb{E}(\bar{X}) - \mathbb{E}\left(\frac{1}{2}\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(x_i) - \frac{1}{2} = \frac{2\theta + 1}{2} - \frac{1}{2} = \theta + \frac{1}{2} - \frac{1}{2} = \theta$$

Por lo tanto, $\hat{\theta}_{MM}$ sí es insesgado.

Suficiencia

Utilizamos el teorema del cociente del estadístico suficiente minimal para θ . Dado una función $T(X)$ y para cualesquiera muestras observadas X, Y , realizamos el cociente $\frac{f(X|\theta)}{f(Y|\theta)}$, si no depende de θ sii $T(X) = T(Y)$ entonces $T(X)$ es suficiente minimal para θ .

$$\frac{f(X|\theta)}{f(Y|\theta)} = \frac{1_{\{X_{(n)}-1 < \theta < X_{(1)}\}}}{1_{\{Y_{(n)}-1 < \theta < Y_{(1)}\}}}$$

¿Qué valores puede tomar el numerador y el denominador?

$$1_{\{X_{(n)}-1 < \theta < X_{(1)}\}} = \begin{cases} 1, & \text{si } \theta \in (X_{(n)} - 1, X_{(1)}) \\ 0, & \text{en } \theta \notin (X_{(n)} - 1, X_{(1)}) \end{cases}$$

$$1_{\{Y_{(n)}-1 < \theta < Y_{(1)}\}} = \begin{cases} 1, & \text{si } \theta \in (Y_{(n)} - 1, Y_{(1)}) \\ 0, & \text{en } \theta \notin (Y_{(n)} - 1, Y_{(1)}) \end{cases}$$

Tenemos dos casos, (omitimos $f(Y|\theta) = 0$ en el denominador porque es una indeterminación, sin embargo, no dependería de θ)

$$\frac{f(X|\theta)}{f(Y|\theta)} = 1 \Leftrightarrow \theta \in (X_{(n)} - 1, X_{(1)}), \theta \notin (Y_{(n)} - 1, Y_{(1)})$$

$$\frac{f(X|\theta)}{f(Y|\theta)} = 0 \Leftrightarrow \theta \notin (X_{(n)} - 1, X_{(1)}), \theta \in (Y_{(n)} - 1, Y_{(1)})$$

El cociente no depende de θ sii

$$(X_{(n)} - 1, X_{(1)}) = (Y_{(n)} - 1, Y_{(1)})$$

$$\Rightarrow X_{(n)} - 1 = Y_{(n)} - 1 \Rightarrow X_{(n)} = Y_{(n)} \wedge X_{(1)} = Y_{(1)}$$

\Rightarrow El vector de estadísticos $(X_{(n)}, X_{(1)})$ son los únicos estimadores suficientes minimales.

In [1]: *#Código para cargar el conjunto de datos, calcular los estimadores y realizar las gráficas.*

```
In [2]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
import pylab
```

```
In [3]: datos1 = pd.read_csv('dataEj1.txt')
```

In [4]: `datos1.head()`

Out[4]:

	x
0	0.257329
1	-0.111362
2	0.376463
3	-0.002884
4	-0.229582

In [5]: `MuestraAleatoria1 = np.asarray(datos1['x'].values.tolist())`

```
In [6]: #Función de densidad Uniforme
def Uniforme(x,a,b):
    if a<x<b:
        r= 1/(b-a)
    else:
        r = 0
    return r
#Estimador por el método de momentos
def ThetaMM(X):
    n= len(X)
    Promedio = sum(X[i] for i in range(n))
    Xbarra = (1/n)*Promedio
    return (2*Xbarra - 1)/2
#Estimador de Máxima Verosimilitud
def ThetaMLE(X,w1,w2):
    Xn = max(X)
    X1 = min(X)
    if w1>=0 and w2 >=0 and (w1+w2==1):
        ThetaMLE = w1*(Xn-1)+w2*(X1)
    return ThetaMLE
```

1.2 Con ayuda de la muestra aleatoria observada, dataEj1.txt , calcule la estimaciones en ambos casos y quédese con alguna de las dos, justificando su respuesta.

Posibles estimadores a elegir:

In [7]: `ThetaMM(MuestraAleatoria1)`

Out[7]: `-0.498538219173369`

In [8]: `ThetaMLE(MuestraAleatoria1,0.5,0.5)`

Out[8]: `-0.499965088092722`

```
In [9]: min(MuestraAleatoria1)
```

```
Out[9]: -0.499822691315785
```

```
In [10]: max(MuestraAleatoria1)-1
```

```
Out[10]: -0.500107484869659
```

En este caso, tomaremos la segunda estimación $\hat{\theta}_{MLE}$ porque es insesgado y (no estoy seguro aquí) es función de los estadísticos suficientes minimales.

1.3 Finalmente haga un histograma (recuerdo normalizarlo) con los datos y encime la función de densidad $f(x|\hat{\theta})$, con $\hat{\theta}$ la estimación elegida del inciso anterior.

```
In [11]: Dominio=np.arange(min(MuestraAleatoria1)-0.1,max(MuestraAleatoria1)+0.1,0.01)
Rango=[]
for i in range(len(Dominio)):
    Rango.append(Uniforme(a=ThetaMLE(MuestraAleatoria1,0.5,0.5), b=ThetaMLE(MuestraAleatoria1,0.5,0.5) +1 ,x=Dominio[i]))
fig, (ax1, ax2) = plt.subplots(1,2, figsize=[12,5])
ax1.hist(MuestraAleatoria1,density=True)
ax1.title.set_text('Histograma de datos')
ax2.hist(MuestraAleatoria1,density=True)
ax2.plot(Dominio,Rango)
ax2.title.set_text('Histograma de datos con '+ r'$f(x|\hat{\theta})$')
plt.show()
```

