

Métodos estadísticos

Tarea 2

González Paz Edgar

Considere una muestra aleatoria X_1, \dots, X_n con función de densidad que proviene de una $Normal(\mu, \sigma^2)$, ambos parámetros desconocidos, se sabe que $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ y $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ y además son independientes.

1. Construya una prueba de hipótesis para el contraste $H_0 : \mu = 0$ vs $H_1 : \mu \neq 0$ de tamaño $\alpha = 0.05$.

La función de densidad de una $N(\mu, \sigma^2)$.

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

La función de verosimilitud es

$$L(\mu, \sigma^2|X) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \mathbb{1}_{\{x_i \in \mathbb{R}\}} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

Sea $\theta = (\mu, \sigma^2)$ y el estadístico del cociente de verosimilitud es de la siguiente manera:

$$\lambda(X) = \frac{\sup_{\theta \in \Theta_0} L(\theta|X)}{\sup_{\theta \in \Theta} L(\theta|X)}$$

donde el espacio paramétrico de θ es $\Theta = \{\mu, \sigma^2 | -\infty < \mu < \infty, \sigma^2 > 0\}$. El subconjunto de la hipótesis nula es $\Theta_0 = \{\mu, \sigma^2 | \mu = 0, \sigma^2 > 0\}$ y para la hipótesis alternativa es $\Theta_1 = \{\mu, \sigma^2 | \mu \neq 0, \sigma^2 > 0\}$.

Recordemos que

$$\sigma_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mu})^2$$

Para el numerador tomamos a $\mu = 0$, ahora bien, σ_0^2 se vería de la siguiente manera:

$$\sigma_0^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - 0)^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$$

Entonces

$$\begin{aligned}\sup_{\theta \in \Theta_0} L(\theta|X) &= \left(\frac{1}{\sqrt{2\pi\sigma_0^2}} \right)^n \exp\left(-\frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2 \right) = \\ &= (2\pi\sigma_0^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right) \\ \Rightarrow \sup_{\theta \in \Theta_0} L(\theta|X) &= (2\pi\sigma_0^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right)\end{aligned}$$

Para $\sup_{\theta \in \Theta} L(\theta|X)$, por el método de máxima verosimilitud, los estimadores de máxima verosimilitud $\hat{\mu}_{MLE}$ y $\hat{\sigma}_{MLE}$ son de la siguiente forma:

$$\begin{aligned}\hat{\mu}_{MLE} &= \frac{1}{n} \sum_{i=1}^n x_i = \bar{X} \\ \hat{\sigma}_{MLE} &= \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_{MLE})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2 \\ \sup_{\theta \in \Theta} L(\theta|X) &= (2\pi\hat{\sigma}_{MLE}^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\hat{\sigma}_{MLE}^2} \sum_{i=1}^n (x_i - \hat{\mu}_{MLE})^2 \right) = \\ &= (2\pi\hat{\sigma}_{MLE}^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right) \\ \Rightarrow \sup_{\theta \in \Theta} L(\theta|X) &= (2\pi\hat{\sigma}_{MLE}^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right)\end{aligned}$$

El estadístico $\lambda(X)$

$$\begin{aligned}\lambda(X) &= \frac{\sup_{\theta \in \Theta_0} L(\theta|X)}{\sup_{\theta \in \Theta} L(\theta|X)} = \frac{(2\pi\sigma_0^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right)}{(2\pi\hat{\sigma}_{MLE}^2)^{-\frac{n}{2}} \exp\left(-\frac{n}{2} \right)} = \\ &= \left(\frac{\sigma_0^2}{\hat{\sigma}_{MLE}^2} \right)^{-\frac{n}{2}} = \left(\frac{\hat{\sigma}_{MLE}^2}{\sigma_0^2} \right)^{\frac{n}{2}} = \left(\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sum_{i=1}^n x_i^2} \right)^{\frac{n}{2}}\end{aligned}$$

La región de rechazo es la siguiente:

$$RR = \left\{ X \left| \left(\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sum_{i=1}^n x_i^2} \right)^{\frac{n}{2}} \leq c \right. \right\}$$

Por una parte, sabemos que $\sigma_0^2 = \sum_{i=1}^n x_i^2 = \sum_{i=1}^n (x_i - \bar{X})^2 + n\bar{X}^2$

$$\begin{aligned}
& \left(\frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sum_{i=1}^n x_i^2} \right)^{\frac{n}{2}} \leq c \\
\Rightarrow & \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{\sum_{i=1}^n (x_i - \bar{X})^2 + n\bar{X}^2} \leq c^{\frac{2}{n}} \\
\Rightarrow & \frac{1}{1 + \frac{n\bar{X}^2}{\sum_{i=1}^n (x_i - \bar{X})^2}} \leq c^{\frac{2}{n}} \\
& \text{Sea } c_1 = c^{\frac{2}{n}}, \\
\Rightarrow & \frac{1}{c_1} \leq 1 + \frac{n\bar{X}^2}{\sum_{i=1}^n (x_i - \bar{X})^2} \\
\Rightarrow & \frac{1}{c_1} - 1 \leq \frac{n\bar{X}^2}{\sum_{i=1}^n (x_i - \bar{X})^2} \\
& \text{Sea } c_2 = \frac{1}{c_1} - 1 \\
\Rightarrow c_2 \leq & \frac{(\frac{1}{n-1})n\bar{X}^2}{(\frac{1}{n-1})\sum_{i=1}^n (x_i - \bar{X})^2} = \frac{(\frac{1}{n-1})n\bar{X}^2}{S^2} \\
\Rightarrow (n-1)c_2 \leq & \frac{n\bar{X}^2}{S^2} \\
\Rightarrow (n-1)c_2 \leq & \frac{\sqrt{n}\bar{X}^2}{S} \\
\Rightarrow \sqrt{(n-1)c_2} \leq & \sqrt{\left(\frac{\sqrt{n}\bar{X}}{S}\right)^2} \\
& \text{Sea } \sqrt{(n-1)c_2} = k \\
\Rightarrow k \leq & \sqrt{\left(\frac{\sqrt{n}\bar{X}}{S}\right)^2} \\
\Rightarrow k \leq & \left| \frac{\sqrt{n}\bar{X}}{S} \right|
\end{aligned}$$

Y entonces,

$$RR = \left\{ X \left| \left| \frac{\sqrt{n}\bar{X}}{S} \right| \geq k \right. \right\}$$

Ahora bien, reescribimos:

$$\frac{\sqrt{n}\bar{X}}{S} = \frac{\bar{X} - 0}{\sqrt{\frac{S^2}{n}}} = \frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}}$$

Sea $T = \frac{\sqrt{n}\bar{X}}{S}$, entonces $T \sim t_{n-1}$ y la Región de Rechazo se ve de la manera:

$$RR = \{X \mid |T| \geq k\} \text{ para algún } k \in \mathbb{R}$$

Buscamos $\mathbb{P}(\text{Error tipo I}) = \mathbb{P}(X \in RR | \theta \in \Theta_0) = \alpha$

$$\begin{aligned} \mathbb{P}(\text{Error tipo I} | \mu = 0) &= \mathbb{P}(|T| \geq k | \mu = 0) = \\ || \text{Simétrica en el origen} || &= 2\mathbb{P}(T \geq k | \mu = 0) = \alpha \\ \Rightarrow \mathbb{P}(T \geq k | \mu = 0) &= \frac{\alpha}{2} \end{aligned}$$

Sabemos que $T \sim t_{n-1}$ entonces tomamos a $k = t_{n-1, 1-\frac{\alpha}{2}}$

$$\Rightarrow \mathbb{P}(|T| \geq k) = \mathbb{P}\left(|T| \geq t_{n-1, 1-\frac{\alpha}{2}}\right) = \alpha$$

La región de rechazo es:

$$RR = \left\{X \mid t_{n-1, 1-\frac{\alpha}{2}} < |T| \right\}$$

Encontrando el valor de $t_{n-1, 1-\frac{\alpha}{2}}$ con $\alpha = 0.05$ y $n = 25$ en valores de tablas o evaluando el valor en la inversa de la función de distribución. El valor es 2.0638.

Entonces la región de rechazo es de la forma:

$$RR = \{X \mid 2.0638 < |T|\}$$

Para el p-value, supongamos que se rechaza bajo la muestra observada, es decir,

$$\{X \mid 3.2958 < |T|\}$$

Consideramos que bajo la m.a.o., $T = 3.2958$.

$$\begin{aligned} \Rightarrow \mathbb{P}(3.2958 < |T|) &= ||\text{Simetría}|| = 2\mathbb{P}(3.2958 < T) = \\ 2(1 - \mathbb{P}(T < 3.2958)) &= p\text{-value} \\ T &\sim t_{24} \end{aligned}$$

2. Con ayuda de la muestra aleatoria observada, data2Ej4.txt, diga si se rechaza o no se rechaza la hipótesis nula y calcule el p-value.

```
In [1]: #Librerías para las distribuciones de la t-student, ji-cuadrada y la t-student no
from scipy.stats import t, chi2, nct
```

```
In [2]: #Cargamos la m.a.o.
import pandas as pd
datos_4 = pd.read_csv('data2Ej4.txt')
```

In [3]: `datos_4.head()`

Out[3]:

| | x |
|---|-----------|
| 0 | 1.708724 |
| 1 | 0.769615 |
| 2 | -1.260394 |
| 3 | 1.742702 |
| 4 | 2.300945 |

In [4]: `datos_4.shape`

Out[4]: (25, 1)

In [5]: `import numpy as np`
`Muestra_Aleatoria_Observada = np.asarray(datos_4['x'].values.tolist())`

In [6]: `#M.a.o.`
`Muestra_Aleatoria_Observada`

Out[6]: array([1.70872406, 0.76961521, -1.26039356, 1.74270239, 2.30094473,
 0.05077468, 1.35129325, 0.20134414, 0.26227203, -0.42621713,
 0.81476031, 0.72918117, -0.15321172, 0.91067085, -0.39005322,
 0.72655107, 0.15187769, 0.3779972 , 2.7231732 , 1.73695479,
 0.0895813 , -0.80422873, -0.39844238, 1.91218168, 1.58635116])

In [7]: `def MediaMuestral(x):`
 `n = len(x)`
 `y = (1/n)*sum(x)`
 `return y`

In [8]: `def Cuasivarianza(x):`
 `n = len(x)`
 `y = (1/(n-1))*sum((x[i] - MediaMuestral(x))**2 for i in range(n))`
 `return y`

In [9]: `def Sigma_MLE(x):`
 `n = len(x)`
 `y = (1/(n))*sum((x[i] - MediaMuestral(x))**2 for i in range(n))`
 `return y`

In [10]: `def T(x, media_hipnul):`
 `n = len(x)`
 `y = (MediaMuestral(x) - media_hipnul)/(np.sqrt(Cuasivarianza(x)/n))`
 `return y`

In [11]: `T(Muestra_Aleatoria_Observada, media_hipnul=0)`

Out[11]: 3.295825419112768

```
In [14]: def PruebaHipotesis(MA, MHP, alpha):
    Estadistico_T = T(x=MA, media_hipnul=MHP)
    n = len(MA)
    MM_MA = MediaMuestral(MA)
    Cuasivarianza_MA = Cuasivarianza(MA)
    #Es la cota de la región de rechazo
    cota_decision = t.ppf(1-(alpha/2), df= n-1)

    print('La muestra observada es: '+str(MA)+'\n')
    print('El tamaño de la muestra es: '+str(n))
    print('La media muestral es: '+str(MM_MA))
    print('La cuasivarianza es: '+str(Cuasivarianza_MA))
    print('El valor del estadístico T es: '+str(Estadistico_T))
    print('La cota de decisión es: '+str(cota_decision)+'\n')

    decision = abs(Estadistico_T) > cota_decision

    if decision == 1:
        print('El estadístico en valor absoluto T='+str(Estadistico_T)+' es mayor al valor '+str(cota_decision))
    else:
        print('El estadístico en valor absoluto T='+str(Estadistico_T)+' es menor al valor '+str(cota_decision))

    p_value = 2*(1-t.cdf(Estadistico_T, df=24))

    decision_2 = p_value > alpha

    if decision_2 == True:
        print('El valor del p-value: '+str(p_value)+' es mayor al valor '+str(alpha))
    if decision_2 == False:
        print('El valor del p-value: '+str(p_value)+' es menor al valor '+str(alpha))
```

In [15]: `PruebaHipotesis(MA=Muestra_Aleatoria_Observada, MHP=0, alpha=0.05)`

```
La muestra observada es: [ 1.70872406  0.76961521 -1.26039356  1.74270239  2.30
094473  0.05077468
 1.35129325  0.20134414  0.26227203 -0.42621713  0.81476031  0.72918117
-0.15321172  0.91067085 -0.39005322  0.72655107  0.15187769  0.3779972
 2.7231732  1.73695479  0.0895813 -0.80422873 -0.39844238  1.91218168
 1.58635116]
```

```
El tamaño de la muestra es: 25
La media muestral es: 0.6685761668633025
La cuasivarianza es: 1.0287583963320184
El valor del estadístico T es: 3.295825419112768
La cota de decisión es: 2.0638985616280205
```

```
El estadístico en valor absoluto T=3.295825419112768 es mayor al valor 2.063898
5616280205, por lo tanto se rechaza la hipótesis nula.
El valor del p-value: 0.0030427364777887433 es menor al valor 0.05, por lo tant
o se rechaza la hipótesis nula.
```

4. Encontrar un intervalo de confianza

Para el intervalo de confianza, definimos la región de no rechazo:

$$A(\theta_0) = \left\{ X \mid t_{n-1; \frac{\alpha}{2}} < T < t_{n-1; 1-\frac{\alpha}{2}} \right\}$$

Sea el conjunto aleatorio $C(X) = \{\theta_0 \in \Theta \mid X \in A(\theta_0)\}$ Entonces

$$\begin{aligned} C(X) &= \left\{ \mu_0 \mid t_{n-1; \frac{\alpha}{2}} < T < t_{n-1; 1-\frac{\alpha}{2}} \right\} = \\ &= \left\{ \mu_0 \mid t_{n-1; \frac{\alpha}{2}} < \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} < t_{n-1; 1-\frac{\alpha}{2}} \right\} = \\ &= \left\{ \mu_0 \mid -t_{n-1; 1-\frac{\alpha}{2}} < \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} < t_{n-1; 1-\frac{\alpha}{2}} \right\} = \\ &= \left\{ \mu_0 \mid -t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} < \bar{X} - \mu_0 < t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right\} = \\ &= \left\{ \mu_0 \mid -t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} - \bar{X} < -\mu_0 < t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} - \bar{X} \right\} = \\ &= \left\{ \mu_0 \mid \bar{X} - t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} < \mu_0 < \bar{X} + t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right\} \\ &\Rightarrow \left(\bar{X} - t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1; 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right) \text{ es un intervalo de confianza para } \mu_0. \end{aligned}$$

```
In [14]: def Intervalo_de_Confianza(Muestra_Aleatoria_Observada, alpha):
n = len(Muestra_Aleatoria_Observada)
MM_MA = MediaMuestral(Muestra_Aleatoria_Observada)
Cuasivarianza_MA = Cuasivarianza(Muestra_Aleatoria_Observada)

Intervalo_confianza_media = []
Intervalo_confianza_media.append(MM_MA - (t.ppf(1-(alpha/2), df= 24)*(np.sqrt(Cuasivarianza_MA))))
Intervalo_confianza_media.append(MM_MA + (t.ppf(1-(alpha/2), df= 24)*(np.sqrt(Cuasivarianza_MA))))

print('El intervalo de confianza para la media es: '+str(Intervalo_confianza_media))
```

```
In [15]: Intervalo_de_Confianza(Muestra_Aleatoria_Observada, alpha=0.05)
```

El intervalo de confianza para la media es: [0.24990308390024746, 1.0872492498263575]

3. Gráficar la función potencia de la prueba.

Para la función potencia:

$$\begin{aligned}
\pi(\theta) &= \mathbb{P}(X \in RR) = \\
&\mathbb{P}\left(T \in (-\infty, -t_{n-1, 1-\frac{\alpha}{2}}) \cup (t_{n-1, 1-\frac{\alpha}{2}}, \infty) | \mu = 0\right) = \\
&1 - \mathbb{P}\left(T \notin (-\infty, -t_{n-1, 1-\frac{\alpha}{2}}) \cup (t_{n-1, 1-\frac{\alpha}{2}}, \infty) | \mu = 0\right) = \\
&1 - \mathbb{P}\left(T \in (-t_{n-1, 1-\frac{\alpha}{2}}, t_{n-1, 1-\frac{\alpha}{2}}) | \mu = 0\right) = \\
&1 - \mathbb{P}\left(-t_{n-1, 1-\frac{\alpha}{2}} < \frac{\bar{X}}{\sqrt{\frac{S^2}{n}}} < t_{n-1, 1-\frac{\alpha}{2}} | \mu = 0\right) = \\
&1 - \mathbb{P}\left(-t_{n-1, 1-\frac{\alpha}{2}} < \frac{(\bar{X} - \mu) + \mu}{\sqrt{\frac{S^2}{n}}} < t_{n-1, 1-\frac{\alpha}{2}} | \mu = 0\right) = \\
&1 - \mathbb{P}\left(-t_{n-1, 1-\frac{\alpha}{2}} < \frac{\frac{(\bar{X} - \mu)}{\sqrt{\frac{\sigma^2}{n}}} + \frac{\mu}{\sqrt{\frac{\sigma^2}{n}}}}{\frac{\sqrt{\frac{S^2}{n}}}{\sqrt{\frac{\sigma^2}{n}}}} < t_{n-1, 1-\frac{\alpha}{2}} | \mu = 0\right) = \\
&1 - \mathbb{P}\left(-t_{n-1, 1-\frac{\alpha}{2}} < \frac{\frac{(\bar{X} - \mu)}{\sqrt{\frac{\sigma^2}{n}}} + \frac{\mu}{\sqrt{\frac{\sigma^2}{n}}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2}}}} < t_{n-1, 1-\frac{\alpha}{2}} | \mu = 0\right)
\end{aligned}$$

$$\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0, 1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Entonces $W_{n-1} = \frac{\frac{(\bar{X} - \mu)}{\sqrt{\frac{\sigma^2}{n}}} + \frac{\mu}{\sqrt{\frac{\sigma^2}{n}}}}{\frac{\sqrt{\frac{S^2}{n}}}{\sqrt{\frac{\sigma^2}{n}}}} \sim t_{n-1, \frac{\mu}{\sqrt{\frac{\sigma^2}{n}}}}$, una T-student con n-1 grados de libertad y un parámetro de descentralización de $\frac{\mu}{\sqrt{\frac{\sigma^2}{n}}}$

$$\begin{aligned}
\Rightarrow \pi(\theta) &= 1 - \mathbb{P}\left(-t_{n-1, 1-\frac{\alpha}{2}} < W_{n-1} < t_{n-1, 1-\frac{\alpha}{2}}\right) = \\
&1 - (F_{W_{n-1}}(t_{n-1, 1-\frac{\alpha}{2}}) - F_{W_{n-1}}(-t_{n-1, 1-\frac{\alpha}{2}}))
\end{aligned}$$

```
In [16]: import matplotlib.pyplot as plt
%matplotlib inline
```



```
In [17]: def FuncionPotencia(Muestra_Aleatoria_Observada, med_hip_nul, alpha):
n = len(Muestra_Aleatoria_Observada)
def Sigma_MLE(x):
n = len(x)
y = (1/(n))*(sum((x[i] - MediaMuestral(x))**2 for i in range(n)))
return y

z = t.ppf(1-(alpha/2), df= n -1)

Dominio_mu=np.arange(med_hip_nul-2.5, med_hip_nul+2.5 ,0.01)
Rango_Funcion_Potencia = []
for i in range(len(Dominio_mu)):
Rango_Funcion_Potencia.append(1 - (nct.cdf(z, n-1, (Dominio_mu[i]/(np.sqrt(Sigma_MLE(Muestra_Aleatoria_Observada))))))
plt.plot(Dominio_mu, Rango_Funcion_Potencia)
plt.title('Función potencia')
```

```
In [18]: Sigma_MA = Sigma_MLE(Muestra_Aleatoria_Observada)
```

```
In [19]: FuncionPotencia(Muestra_Aleatoria_Observada, med_hip_nul=0, alpha=0.05)
```

